



Электронный учебно-методический комплекс по учебной дисциплине "Теория вероятностей и математическая статистика" для специальности:

310304 «Информатика»

Оглавление | Программа | Теория | Практика | Контроль знаний | Об авторах

ТЕМА 7. ЧИСЛОВЫЕ ХАРАКТЕРИСТИКИ СИСТЕМ СВ.

7.1 Смешанные моменты двумерной случайной величины

Смешанным начальным моментом порядка $k+s$ называется математическое ожидание произведения X^k и Y^s :

$$\alpha_{k,s}(X, Y) = M[X^k Y^s] \quad (13.1)$$

Смешанным центральным моментом порядка $k+s$ называется математическое ожидание произведения центрированных величин \hat{X}^k и \hat{Y}^s :

$$\mu_{k,s}(X, Y) = M[\hat{X}^k \hat{Y}^s] \quad (13.2)$$

где $\hat{X} = M[(X - m_x)]$, $\hat{Y} = M[(Y - m_y)]$ - центрированные случайные величины.

Расчетные формулы:

$$\alpha_{k,s}(x, y) = \begin{cases} \sum_{i=1}^n \sum_{j=1}^m x_i^k y_j^s p_{ij}, & \text{ДСВ} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^k y^s f(x, y) dx dy, & \text{НСВ} \end{cases} \quad (13.3)$$

$$\mu_{k,s}(x, y) = \begin{cases} \sum_{i=1}^n \sum_{j=1}^m (x_i - m_x)^k (y_j - m_y)^s p_{ij}, & \text{ДСВ} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - m_x)^k (y - m_y)^s f(x, y) dx dy, & \text{НСВ} \end{cases} \quad (13.4)$$

где p_{ij} - элементы матрицы вероятностей дискретной величины (X, Y) ;

$f(x, y)$ - совместная плотность вероятности непрерывной величины (X, Y) .

Рассмотрим наиболее часто используемые начальные и центральные моменты:

$$\alpha_{0,0}(x, y) = m_{0,0}(x, y) = 1;$$

Первые начальные моменты представляют собой уже известные нам **математические ожидания** величин X и Y , входящих в систему:

$$\alpha_{1,0}(x, y) = m_x; \quad \alpha_{0,1}(x, y) = m_y. \quad (13.5)$$

Совокупность математических ожиданий представляет собой характеристику положения системы. Геометрически это координаты средней точки на плоскости, вокруг которой происходит рассеивание случайных точек (X, Y) .

$$\begin{aligned} m_{1,0}(x, y) &= M[X - m_x] = 0 & m_{0,1}(x, y) &= M[Y - m_y] = 0; \\ a_{2,0}(x, y) &= a_2(x) & a_{0,2}(x, y) &= a_2(y) \end{aligned} \quad (13.6)$$

На практике широко используются вторые центральные моменты системы. Два из них представляют собой **дисперсии**, которые характеризуют **рассеивание** случайной точки в направлении осей OX и OY :

$$m_{2,0}(x, y) = M[(X - m_x)^2] = D[X] = D_x; \quad m_{0,2}(x, y) = M[(Y - m_y)^2] = D[Y] = D_y; \quad (13.7)$$

7.2. Ковариация. Коэффициент корреляции.

Особую роль играет центральный момент порядка 1+1 или второй смешанный центральный момент, который называется **ковариацией** или **корреляционным моментом**

$$m_{1,1}(x, y) = K_{xy} = M[\hat{X} \hat{Y}] \quad (13.8)$$

Ковариация представляет собой математическое ожидание произведения центрированных случайных величин X и Y и характеризует степень линейной статистической зависимости величин X и Y относительно точки (m_x, m_y) :

$$K_{xy} = \mu_{xy} = M[(X - m_x) \cdot (Y - m_y)], \quad (13.9)$$

Или

$$\begin{aligned} K_{xy} &= M[(X - m_x) \cdot (Y - m_y)] = M[XY - X m_y - Y m_x + m_x m_y] = \\ &= M[XY] - M[X m_y] - M[Y m_x] + m_x m_y = M[XY] - m_x m_y. \end{aligned} \quad (13.10)$$

Расчетные формулы для определения ковариации:

$$K_{xy} = \begin{cases} \sum_i \sum_j (x_i - m_x)(y_j - m_y) p_{ij} = \sum_i \sum_j x_i y_j p_{ij} - m_x m_y, \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - m_x)(y - m_y) f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f(x, y) dx dy - m_x m_y. \end{cases} \quad (13.11)$$

Свойства корреляции:

1. $K_{xy} = K_{yx}$. Это свойство очевидно.

2. Корреляционный момент двух независимых случайных величин X и Y равен нулю.

Доказательство: т.к. случайные величины X и Y - независимы, то и их совместная плотность распределения представляется произведением плотностей распределения случайных величин $f_x(x)$ и $f_y(y)$. Тогда:

$$K_{xy} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyf(x, y) dx dy - m_x m_y = \left(\int_{-\infty}^{\infty} xf_x(x) dx \right) \cdot \left(\int_{-\infty}^{\infty} yf_y(y) dy \right) - m_x m_y = 0.$$

3. Абсолютная величина корреляционного момента двух случайных величин не превышает среднего геометрического их дисперсий

$$|K_{xy}| \leq \sigma_x \cdot \sigma_y \quad \text{или} \quad |K_{xy}| \leq \sqrt{D_x \cdot D_y}$$

Доказательство — Введем в рассмотрение случайные величины $Z_1 = \sigma_y X - \sigma_x Y$,
 $Z_2 = \sigma_y X + \sigma_x Y$, и вычислим их дисперсии

$$D(Z_1) = M[Z - m_z]^2 = 2\sigma_x^2 \sigma_y^2 - 2\sigma_x \sigma_y \cdot K_{xy}$$

$$D(Z_2) = M[Z - m_z]^2 = 2\sigma_x^2 \sigma_y^2 + 2\sigma_x \sigma_y \cdot K_{xy}$$

Т. к. дисперсия всегда неотрицательна, то

$$2\sigma_x^2 \sigma_y^2 - 2\sigma_x \sigma_y \cdot K_{xy} \geq 0 \quad \text{р} \quad \sigma_x \sigma_y \geq K_{xy}$$

и

$$2\sigma_x^2 \sigma_y^2 + 2\sigma_x \sigma_y \cdot K_{xy} \geq 0 \quad \text{р} \quad -\sigma_x \sigma_y \leq K_{xy}$$

$$\text{Отсюда} \quad -\sigma_x \sigma_y \leq K_{xy} \leq \sigma_x \sigma_y \quad \text{р} \quad |K_{xy}| \leq \sigma_x \sigma_y$$

Если $K_{xy} \neq 0$, случайные величины X и Y называются *коррелированными*. Если $K_{xy} = 0$, то необязательно, что X и Y независимы. В этом случае они называются *некоррелированными*. Итак, из коррелированности двух случайных величин следует их зависимость, но из зависимости еще не вытекает их коррелированность. Из независимости двух случайных величин следует их некоррелированность, но из некоррелированности еще нельзя заключить о независимости этих величин.

Величина ковариации зависит единиц измерения каждой из случайных величин, входящих в систему и от того, насколько каждая из случайных величин отклоняется от своего математического ожидания (одна – мало, вторая – сильно, все равно K_{xy} будет мал).

Поэтому для характеристики связи между X и Y в чистом виде переходят к безразмерной характеристике, которая называется **Коэффициент корреляции** r_{xy} характеризует степень линейной зависимости величин:

$$r_{xy} = \frac{K_{xy}}{\sqrt{D_x D_y}} = \frac{K_{xy}}{\sigma_x \sigma_y} \quad (13.12)$$

Свойства коэффициента корреляции:

1. Абсолютная величина коэффициента корреляции двух случайных величин не превышает единицы: $|r_{xy}| \leq 1$
2. $|r_{xy}| = 1$ если $Y = aX + b$

Доказательство: $M(Y) = M[aX + b] = aM(X) + b$
 Подставим в выражение
 $K_{xy} = M\{[X - M(X)][Y - M(Y)]\} = M\{[X - M(X)][aX + b - aM(X) - b]\} =$
 $= aM\{[X - M(X)][X - M(X)]\} = aM[X - M(X)]^2 = aD(X) = a\sigma_x^2$
 т.к. $[Y - M(Y)] = [aX + b - aM(X) - b] = a[X - M(X)]$

Найдем дисперсию Y : $D(Y) = M[Y - M(Y)]^2 = a^2 M[X - M(X)]^2 = a^2 \sigma_x^2$, т.е.

$$\sigma_y = |a| \sigma_x, \quad \text{коэффициент корреляции:} \quad r_{xy} = \frac{K_{xy}}{\sigma_x \sigma_y} = \frac{a \sigma_x^2}{\sigma_x (|a| \sigma_x)} = \frac{a}{|a|} \quad \text{р} \quad |r_{xy}| = 1$$

Коэффициент корреляции служит для оценки тесноты линейной связи между X и Y : чем ближе абсолютная величина коэффициента корреляции к 1, тем связь сильнее, чем ближе к 0, тем слабее.

3. Если величины X и Y независимы, то $r_{xy} = 0$.

7.3. Числовые характеристики системы случайных величин

Как и в случае одномерных случайных величин, при невозможности точно установить законы распределения, применяют приближенное описание системы случайных величин с помощью минимального количества числовых характеристик.

В качестве основных числовых характеристик используем следующие:

1. **Вектор математических ожиданий** $M = (m_1, m_2, \dots, m_n)$ – характеризующих средние значения величин

$$m_i = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} x_i f(x_1, \dots, x_n) dx_1 \dots dx_n$$

2. **Вектор дисперсий** $D = (D_1, D_2, \dots, D_n)$ – характеризующих их рассеивание

$$D_i = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} (x_i - m_i)^2 f(x_1, \dots, x_n) dx_1 \dots dx_n$$

3. **Корреляционная матрица**

$$K_{ij} = M \left[\overset{\circ}{X}_i \overset{\circ}{X}_j \right],$$

где $\overset{\circ}{X}_i = X_i - m_i$, $\overset{\circ}{X}_j = X_j - m_j$ или матрица коэффициентов корреляции

$$r_{ij} = \frac{K_{ij}}{\sigma_x \sigma_y},$$

характеризующих попарную корреляцию всех величин, входящих в систему.

Дисперсия каждой из случайных величин X_i есть, по существу, не что иное, как

$$D_i = K_{ii} = M[X_i^2] = M[\dot{X}_i \cdot \dot{X}_i]$$

корреляционный момент X_i и той же величины X_i :

, поэтому корреляционная матрица и матрица коэффициентов корреляции принимает вид:

$$\|K_{ij}\| = \begin{vmatrix} D_1 & K_{12} & \dots & K_{1n} \\ K_{21} & D_2 & \dots & K_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ K_{n1} & K_{n2} & \dots & D_n \end{vmatrix},$$

где

$$K_{ij} = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} (x_i - m_i)(x_j - m_j) f(x_1, \dots, x_n) dx_1 \dots dx_n$$

В случае, когда случайные величины не коррелированы, все элементы, кроме диагональной, равны 0 и корреляционная матрица принимает вид диагональной матрицы:

$$\|K_{ij}\| = \begin{vmatrix} D_1 & 0 & \dots & 0 \\ 0 & D_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & D_n \end{vmatrix}$$

Помимо корреляционной матрицы для описания систем случайных величин может быть использована матрица коэффициентов корреляции. Это матрица, составленная не из корреляционных моментов, а из коэффициентов корреляции (нормированная корреляционная матрица):

$$\|r_{ij}\| = \begin{vmatrix} 1 & r_{12} & \dots & r_{1n} \\ r_{21} & 1 & \dots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ r_{n1} & r_{n2} & \dots & 1 \end{vmatrix},$$

где

$$R_{ij} = \frac{K_{ij}}{\sigma_i \sigma_j} = \frac{K_{ij}}{\sqrt{D_i D_j}}$$

Для некоррелированных случайных величин матрица коэффициентов корреляции вырождается в единичную матрицу:

$$\|r_{ij}\| = \begin{vmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{vmatrix}.$$

7.4. Условные числовые характеристики

Пусть (X, Y) – 2-мерная СВс известным законом распределения $F(X, Y)$ или $f(x, y)$. Условным математическим ожиданием компоненты X называется математическое ожидание СВ X , вычисленное при условии, что СВ Y приняла определенное значение $Y = y_i$ обозначается $M(X|Y)$. Аналогично определяется условное математическое ожидание и для СВ Y .

Используя формулы для вычисления числовых характеристик случайных величин можно вычислить и условные числовые характеристики, заменив безусловные законы распределения на условные.

$$M(X|Y) = \begin{cases} \sum_{i=1}^n x_i \cdot p(x_i / Y = y_j) \\ \int_{-\infty}^{+\infty} x \cdot f_x(x / y) dx \end{cases} \quad \text{и} \quad M(Y|X) = \begin{cases} \sum_{j=1}^m y_j \cdot p(y_j / X = x_i) \\ \int_{-\infty}^{+\infty} y \cdot f_y(y / x) dy \end{cases}$$

Условное математическое ожидание СВ Y при заданном $X = x$: $M[Y / x] = m_{y/x}$ называется регрессией Y на x ; аналогично $M[X / y] = m_{x/y}$ называется регрессией X на y . Графики этих зависимостей от x и y называются **линиями регрессии** или **«кривыми регрессии»**.

Регрессионный анализ позволяет выявить характер связи между величинами. Представим СВ Y в виде линейной функции X :

$$Y \cong g(x) = \alpha X + \beta,$$

где α и β – неизвестные величины.

Теорема. Линейная средняя квадратическая регрессия Y на X имеет вид

$$g(x) = m_y + r_{xy} \frac{\sigma_x}{\sigma_y} (X - m_x),$$

$$\beta = r_{xy} \frac{\sigma_x}{\sigma_y}$$

здесь r_{xy} – коэффициент регрессии Y на X ,

$$y - m_y = r_{xy} \frac{\sigma_x}{\sigma_y} (X - m_x)$$

а прямую $y - m_y = r_{xy} \frac{\sigma_x}{\sigma_y} (X - m_x)$ называют **прямой среднеквадратической регрессии Y на X** . Аналогично можно получить прямую среднеквадратической регрессии X на Y .

Обе прямые проходят через точку (m_x, m_y) , которую называют центром совместного распределения величин X и Y .

Пример 13.1. Определить коэффициент корреляции величин X и Y (См. пример 13.1).

Решение. Определим математические ожидания величин X и Y по формуле (13.3):

$$m_x = \sum_{i=1}^2 \sum_{j=1}^3 x_i p_{ij} = 1,0(0,1 + 0,3 + 0,2) = 0,7,$$

$$m_y = \sum_{i=1}^2 \sum_{j=1}^3 y_j p_{ij} = 0,1(-1,0 + 1,0 + 1,0) = 0,1.$$

Найдем значение K_{xy} по формуле (13.11):

$$K_{xy} = \sum_{i=1}^2 \sum_{j=1}^3 x_i y_j p_{ij} - m_x m_y = 0(-1,0) + 0(0,2) + 1(0,2) + 1(-1,0) + 1(0,3) + 1(0,2) - 0,7(-0,1) = 0,07.$$

Определим дисперсии величин X и Y по формуле (11.4):

$$D_x = \sum_{i=1}^2 \sum_{j=1}^3 (x_i - m_x)^2 p_{ij} = (-0,7)^2(0,1 + 0,3) + (0,3)^2(0,2 + 0,2) = 0,21,$$

$$D_y = \sum_{i=1}^2 \sum_{j=1}^3 (y_j - m_y)^2 p_{ij} = (-1,1)^2(0,1 + 0,2) + (0,1)^2(0,2 + 0,3) + (0,9)^2(0,2 + 0,2) = 0,49.$$

Значение коэффициента корреляции R_{xy} вычислим по формуле

$$r_{xy} = \frac{K_{xy}}{\sqrt{D_x D_y}} = \frac{0,07}{\sqrt{0,21 \cdot 0,49}} \approx 0,22 \quad (11.14)$$

Пример 13.2. Двумерная случайная величина равномерно распределена в области D , ограниченной прямыми $X=0$, $Y=0$ и $X+Y=4$. Определить коэффициент корреляции величин X и Y .

Решение. Запишем в аналитической форме совместную плотность вероятности:

$$f(x, y) = \begin{cases} c, & 0 \leq x \leq 4, 0 \leq y \leq 4 - x \\ 0, & x \notin [0, 4], y \notin [0, 4 - x] \end{cases}$$

Определим c , используя свойства плотности распределения (условие нормировки):

$$\int_0^4 \int_0^{4-x} c dx dy = c \int_0^4 (4-x) dx = c \cdot 8 = 1 \Rightarrow c = \frac{1}{8}.$$

Найдем математическое ожидание и дисперсию величины X по формулам (10.3) и (10.4) соответственно:

$$m_x = \int_0^4 \int_0^{4-x} x \frac{1}{8} dx dy = \frac{1}{8} \int_0^4 x dx \int_0^{4-x} dy = \frac{1}{8} \int_0^4 x(4-x) dx = \frac{4}{3},$$

$$D_x = \int_0^4 \int_0^{4-x} (x - m_x)^2 \frac{1}{8} dx dy = \frac{1}{8} \int_0^4 (x - \frac{4}{3})^2 (4-x) dx = \frac{8}{9}.$$

Так как область D симметрична относительно осей координат, то величины X и Y будут иметь одинаковые числовые характеристики: $m_x = m_y = 4/3$, $D_x = D_y = 8/9$.

Определим корреляционный момент K_{xy} по формуле (11.11):

$$K_{xy} = \int_0^4 \int_0^{4-x} xy \frac{1}{8} dx dy - m_x \cdot m_y = \frac{1}{8} \int_0^4 x dx \int_0^{4-x} y dy - \left(\frac{4}{3}\right)^2 = \frac{1}{16} \int_0^4 x(4-x)^2 dx - \left(\frac{4}{3}\right)^2 = -\frac{4}{9}$$

Коэффициент корреляции величин X и Y будет равен (2.6):

$$r_{xy} = \frac{K_{xy}}{\sqrt{D_x D_y}} = -\frac{1}{2}$$

7.5. Нормальный закон распределения на плоскости

Непрерывная двумерная случайная величина (X, Y) имеет нормальное распределение, если ее совместная плотность вероятности имеет вид

$$f(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-r_{xy}^2}} e^{-\frac{1}{2(1-r_{xy}^2)} \left[\frac{(x-m_x)^2}{\sigma_x^2} - \frac{2r_{xy}(x-m_x)(y-m_y)}{\sigma_x\sigma_y} + \frac{(y-m_y)^2}{\sigma_y^2} \right]}$$

m_x – математическое ожидание случайной величины X .

m_y – математическое ожидание случайной величины Y .

σ_x – среднее квадратичное отклонение СВ X .

σ_y – среднее квадратичное отклонение СВ Y .

r_{xy} – коэффициент корреляции.

Условные законы распределения СВ X и Y также являются нормальными:

$$f_1(x/y) = \frac{1}{\sigma_x\sqrt{2\pi(1-r_{xy}^2)}} e^{-\frac{1}{2(1-r_{xy}^2)} \left[\frac{(x-m_x)^2}{\sigma_x^2} - \frac{r_{xy}(y-m_y)}{\sigma_x} \right]^2};$$

$$f(y/x) = \frac{1}{\sigma_y\sqrt{2\pi(1-r_{xy}^2)}} e^{-\frac{1}{2(1-r_{xy}^2)} \left[\frac{(y-m_y)^2}{\sigma_y^2} - \frac{r_{xy}(x-m_x)}{\sigma_y} \right]^2}.$$

Условные числовые характеристики имеют вид:

$$m[x/y] = m_x + r_{xy}\sigma_x(y-m_y)/\sigma_y; \quad D[x/y] = \sigma_x^2(1-r_{xy}^2);$$

$$m[y/x] = m_y + r_{xy}\sigma_y(x-m_x)/\sigma_x; \quad D[y/x] = \sigma_y^2(1-r_{xy}^2).$$

Для системы нормально распределенных случайных величин линии регрессии $m[x/y]$ и $m[y/x]$ представляют собой прямые линии, т.е. регрессия линейна.

Для двумерной нормально распределенной с.в. – если составляющие некоррелированы, то

они и независимы, т.е. $r_{xy} = 0$.

$$\begin{aligned}
 f(x, y) &= \frac{1}{2\pi\sigma_x\sigma_y} e^{-\frac{1}{2}\left[\frac{(x-m_x)^2}{\sigma_x^2} + \frac{(y-m_y)^2}{\sigma_y^2}\right]} = \\
 &= \frac{1}{\sigma_x\sqrt{2\pi}} e^{-\frac{(x-m_x)^2}{2\sigma_x^2}} \cdot \frac{1}{\sigma_y\sqrt{2\pi}} e^{-\frac{(y-m_y)^2}{2\sigma_y^2}} = f_1(x)f_2(y)
 \end{aligned}$$

Итак, для нормально распределенных составляющих двумерной случайной величины понятия независимости и некоррелированности равносильны.

Можно показать, что двумерная случайная величина (X,Y) распределена нормально, то X и Y связаны линейной корреляционной зависимостью.